



Topic2 Exploring Data


- 数据是对象 (objects) 及其属性 (attributes) 的集合; 变量类型: 连续变量 (Continuous); 名义/类别变量 (Nominal/Categorical); 有序变量 (Ordinal); 区间变量 (Interval); 2. 数据类型 (Types of Data): 数据矩阵 (Data matrix)、文本数据、图音视频数据、交易数据 (Transactions data) 以及图数据 (Graph data); 数据矩阵: $n \times p$ 矩阵; n 行代表对象, p 列代表变量; 文本数据 (Text Data) 中通过 "文档-词项(term)" 矩阵展示词频统计; 交易数据一种特殊的记录数据, 每条记录 (交易) 包含一组项目 (items); 数据质量 (Data Quality): 包括噪声与异常值 (Noise and outliers)、缺失值 (Missing values) 以及采样偏差 (Sampling bias); 噪声是原始值的扰动; 异常值是与其他对象显著不同的; 缺失值成因: 信息未收集和变量对案例不适用比如儿童没有年收入; 采样偏差: 随机采样与总体不匹配; 原因: 便利抽样 cov sam; 类别不平衡; 数据探索 data exploration: 对数据进行初步探索以更好地理解其特征; EDA 探索性数据分析 John tukey 创立; 侧重于可视化: 描述性统计量: 比如频率 fre 众数 mode 位置 location 离散度 spread 偏度 skewness;
- 可视化的方法 (图的类型): 直方图 (histogram) / 2D Histogram 箱线图 (Boxplot): 包括中位数/上四分位下四分位/outliers/数据扩散范围两边; 散点图 (Scatter Plot) 不同变量两两之间的关系; 矩阵图 (Matrix Plot):



Topic5 Model Selection and Regularization

稀疏回归 (Sparse Regression): 给定训练集 (x_i, y_i) , 假设线性模型 $y_i = \beta_0 + \sum_{j=1}^{p_0} \beta_j x_{ij} + \epsilon_i$ 稀疏性假设: 假设 $p_0 \ll p$. 即真实相关的预测变量远小于总变量数; 变量选择的目标: 正确检测出包含信息量的预测变量集合; 区分出冗余变量; 主要关注线性回归模型; 为什么关注变量选择? 多重共线性 (Multicollinearity) 显著性掩盖; 方差膨胀: 总变量太多过拟合导致维度灾难; 可解释性 (Interpretability) 无关变量模型更复杂; 常用的技术: 最优子集选择 **b subset selec**; 信息准则交叉验证; 逐步变量选择 forward/backward; 收缩方法 (Shrinkage methods): 如 Lasso 及其变体; PCA 降维; **最优子集选择**: 遍历拟合所有可能的预测变量组合;






局最优模型; 岭回归 (Ridge Regression): 使用 L2 范数惩罚

参数 lambda 控制回归拟合和系数收缩之间的平衡: 0 为最小二乘估计; 趋于无穷时估计值趋于 0; 展示了随着 lambda 增加, 各变量的标准化系数趋向于 0 的过程; 增加 lambda 会增加偏差(Bias) 但减少方差(Variance); LASSO: 使用 L1 范数惩罚; 通常没有显式解, 需使用二次规划 (QP) 算法求解; Ridge vs. Lasso: 都会收缩系数估计并引入偏差; Lasso 优势: 产生更简单、更具可解释性的模型; Bridge 估计量 (Bridge Estimators) 使用 Lr 范数 R=1 lasso /2 ridge /∞最大值惩罚; 非负 Garrote: 通过缩放因子最小化误差; s.t c_j

$$\min_{\beta} \frac{1}{2} \sum_{i=1}^n \left(y_i - \sum_{j=1}^p c_j \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p c_j \quad \text{其他扩展 (Other Extensions): Elastic Net (弹性网络)混合 L1 与 L2 惩罚;}$$


Group Lasso: 当变量分组时, 整组地包含或剔除变量; 惩罚系数控制回归拟合精度与系数收缩程度之间的权衡; 随着模型复杂度的增加, 偏差逐渐减小, 而方差逐渐增大; 主成分分析 (PCA): 寻找数据主成分方向以及方差最大方向 (但这可能不是信息量最大的); 主成分回归 (Principal Component Regression, PCR) 展示了随着主成分数量增加, PCR 的平方偏差、测试 MSE 和方差的变化趋势

2. 岭回归 (Ridge Regression) 定义与公式 <ul style="list-style-type: none"> 岭回归使用 L_2-范数惩罚, 即系数的平方和: $\lambda \ \beta\ _2^2 = \lambda \sum \beta_j^2$。 优化目标: $\hat{\beta}_{\lambda}^{Ridge} = \operatorname{argmin}_{\beta} (y - X\beta)^T (y - X\beta) + \lambda \ \beta\ _2^2$。 解: 岭回归有解析解 (Closed-form solution): $\hat{\beta}_{\lambda}^{Ridge} = (X^T X + \lambda I_p)^{-1} X^T y$。 性质 <ul style="list-style-type: none"> 收缩作用: 惩罚项会将系数估计值向零收缩 (Shrink towards zero)。 λ 的影响: <ul style="list-style-type: none"> 当 $\lambda = 0$ 时, 就是普通的最小二乘法 (LSE)。 当 $\lambda \rightarrow \infty$ 时, 所有系数趋近于零。 非稀疏性: 岭回归虽然会让系数变小, 但通常不会让系数完全等于零 (除非 λ 无穷大)。它保留了所有变量。 	3. LASSO (Least Absolute Shrinkage and Selection Operator) 定义与公式 <ul style="list-style-type: none"> LASSO 使用 L_1-范数惩罚, 即系数的绝对值之和: $\lambda \ \beta\ _1 = \lambda \sum \beta_j$。 优化目标: $\hat{\beta}_{\lambda}^{Lasso} = \operatorname{argmin}_{\beta} (y - X\beta)^T (y - X\beta) + \lambda \ \beta\ _1$。 解: 一般情况下没有显式解析解, 需要通过二次规划 (QP) 算法求解。 性质 <ul style="list-style-type: none"> 稀疏解 (Sparse Solution): LASSO 的一个关键特性是它能产生稀疏解。这意味着某些系数会恰好变为零。因此, LASSO 可以同时进行参数估计和连续的变量选择。 模型解释性: 由于它剔除了部分变量, LASSO 生成的模型通常比岭回归更简单、更易解释。
---	---




Topic 6 Classification

交叉验证; 交叉验证是一种模型选择技术。它的主要目的是通过调整训练误差来估计测试误差 (Test Error), 从而解释过拟合现象; 数学定义: 输出变量是定性的; 输入变量 x; 分类器 G(x) 目标是最小化误分率 err(G); 分类函数通过 h_k(x) 来构建分类器; 二分类就是 k=2; 分类器为 I 或者 sign(h(x)); 分类边界就是类别 k 与 1: $\{x: h_k(x) = h_1(x)\}$; 线性回归用于分类的问题; 编码问题: 对于多分类问题 (如三种糖尿病), 如果简单地将其编码为 1, 2, 3 并使用线性回归, 由于类别间距离和顺序的假设 (如类型 2 介于类型 1 和妊娠期糖尿病之间) 可能不成立, 会导致模型偏差



- 决策边界对比:**
- 黑色点线 (Black: LDA): 这是 LDA 强行拟合出的直线边界。由于它忽略了方差的差异, 导致在左上角和右下角有明显的分类错误。
 - 绿色实线 (Green: QDA): 这是 QDA 拟合出的曲线边界。它呈现出弯曲的形状, 能够更好地包裹住数据分布的特征, 适应了不同类别方差不一致的情况。
 - 紫色虚线 (Purple: Bayes rule): 真实的最优边界也是弯曲的, QDA 比 LDA 更接近这条真实边界。

二分类可行性: 对于二分类, 将其转换为虚拟变量 (dummy variable) 并拟合




线性回归是可行的; 线性回归估计的概率 $h_k(X)$ 可能小于 0 或大于 1, 且存在“遮蔽问题 (Masking problem)”

(Naive Bayes) 理论: 最小化误差

定义最优分类器把 hx 换成 px 后验概率; 估

计 px 的方法: 判别分析; 逻辑回归; 分类树; 深度神经网络; 估计 $G(x)$: SVM; Boosting; Bagging; 线性判别分析 (LDA) and 二次判别分析 (QDA); 朴素贝叶斯 (Naive Bayes): 不假设特定的分布族, 而是假设在每个类别内, 预测变量之间是相互独立的;




虽然独立性假设通常不成立（引入偏差），但它减少了方差。这种偏差-方差的权衡使得朴素贝叶斯在样本量 n 表现良好；二元逻辑回归 (Binary Logistic Regression)；直观展示了线性回归（直线，可能超出 0-1）与逻辑回归（S 形曲线，限制在 0-1）在预测违约概率时的区别；逻辑回归的拟合：极大似然估计 (MLE)：通过最大化对数似然函数 l(beta) 来估计系数；逻辑回归 vs LDA：两者都产生线性决策边界 (Logit 是线性的)。区别在于拟合过程：逻辑回归使用 MLE（更少假设），LDA 使用均值和协方差的估计（基于正态假设）；分离超平面 (Separating Hyperplane)：分类规则：根据 $f(x^*) > 0$ 或 < 0 将测试点归类为 1 或 -1。点离超平面越远，分类置信度越高；最优分离超平面 (Optimal Separating Hyperplane)：能完美分离训练数据的超平面可能有无限多个，需要选择最好的一个；最优超平面应使得到最近数据点的距离（间隔 Margin）最大化；通过拉格朗日乘子法转化为 Wolfe 对偶形式，利用二次规划 (Quadratic Programming, QP) 求解。

True Neg. (TN)	False Pos. (FP)
False Neg. (FN)	True Pos. (TP)

类模型评估：误分类误差；ROC 曲线 (TP 对 FP 的曲线)；Precision=TP/P；F1 score；AUC = ROC 曲线的面积；混淆矩阵的格式。

Topic1 Review



生观

Page 13: 条件概率与贝叶斯 (Conditional Probability)
 • 条件概率: $P(A|B) = \frac{P(A \cap B)}{P(B)}$ 。
 • 独立性: 若 $P(A \cap B) = P(A)P(B)$ 或 $P(A|B) = P(A)$, 则 A 与 B 独立。
 • 贝叶斯定理: $P(A|B) = \frac{P(A)P(B|A)}{\sum P(A_i)P(B|A_i)}$ 。

- 伯努利分布: $Bern(p)$ 。
- 二项分布: $Bin(n, p)$, 公式 $C_n^n p^n (1-p)^{n-n}$ 。
- 泊松分布: $Poi(\lambda)$, 公式 $\frac{\lambda^n}{n!} e^{-\lambda}$ 。

总体 (Population): 我们试图得出结论的个体的全体集合；样本 (Sample): 被观察到的总体的一部分；关系: 概率论 (Probability) 从总体推导样本性质，推断统计 (Inferential statistics) 从样本推断总

两个事件: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ (减去重复计算的交集部分)。
 三个事件: $P(A \cup B \cup C)$ 需要用到容斥原理, 加回被减去过多的三者交集部分 $+ P(A \cap B \cap C)$ 。

测结

体性质；试验 (Experiment): 任何产生的动作；样本空间

(Sample Space, S): 试验所有可能结果的集合；随机变量 (Random Variable); 离散型随机变量 (Discrete Random Variable): 概率质量函数 (PMF) 和累积分布函数 (CDF); 常见离散分布；连续型随机变量 (Continuous Random Variable): 结果构成实数轴上的区间；概率密度函数 (PDF) 和累积分布函数 (CDF, 积分形式)；中心极限定理(CLT): 样本均值的标准化形式趋近于标准正态分布 $N(0,1)$ 统计推断 (Statistical Inference); 点估计 (Point Estimation): 定义: 若 $E(\hat{\theta}) = \theta$, 则 $\hat{\theta}$ 是无偏的；最小方差无偏估计 (MVUE): 在所有无偏估计量中方差最小的一个；比较: 比较不同估计量的方差大小；矩估计法 (Method of Moments, MM); 令样本矩等于总体矩, 解方程求出参数；

定义: k阶总体矩 $E(X^k)$, k阶样本矩 $\frac{1}{n} \sum X_i^k$


MLE: 使似然函数 $L(\theta) = f(x_1, \dots, x_n; \theta)$ 最大的 θ 值；正态分布: $\mu \hat{=} \bar{x}$, $\sigma^2 = 1/n \sum (x_i - \bar{x})^2$ ；似然函数: 将概率密度函数 (pdf) 中的参数视为变量、数据视为固定值, 得到的关于参数的函数；置信区间: 构建

2. 线性判别分析 (LDA)
 此部分主要依据 Topic 6 Classification (第 12-15 页)。
 推理理论
 • 假设检验: LDA 试图通过估计 $f_k(X)$ (类条件密度) 和 π_k (先验概率) 来计算后验概率 $p_k(X)$ 。
 • 关键假设:
 1. 正态分布: 假设每类数据服从多元正态分布 $X|y=k \sim N_p(\mu_k, \Sigma)$ 。
 2. 方差相等 (Equal Covariance): 假设所有类别共用同一个协方差矩阵 Σ 。这是 LDA 最核心的假设。
 3. 结果: 由于假设方差矩阵相同, 判别函数中的二次项 $X^T \Sigma^{-1} X$ 相互抵消, 剩下的判别函数 $\delta_k(X)$ 是关于 X 的线性函数。
 • 决策边界: 分类边界由线性方程决定, 因此在几何上表现为直线 (或超平面)。

λ 的作用:
 • $\lambda = 0$: 函数 g 会穿过所有训练点 (插值), 可能过拟合。
 • $\lambda \rightarrow \infty$: 平滑样条退化为简单的线性回归 (直线)。
 • 选择: λ 控制偏差-方差权衡, 可以通过交叉验证确定。

区间, 使其以 1-alpha 的概率覆盖真实参数；含义: 重复抽样中约 100(1-alpha)% 的区间包含参数 θ (参数固定, 区间随机)；假设检验: 用数据在 H0 (原假设, 最初假定为真, 通常含等号) 和 Ha (备择假设, 对立, 通常含不等号) 之间做决策；决策: 拒绝 H0 or 不拒绝 H0 (不拒绝 ≠ 接受)。错误类型: Type I 错误 (拒绝真 H0, 概率 = alpha, 即显著性水平)；Type II 错误 (不拒绝假 H0, 概率 = beta)；功效 = 1 - beta (正确拒绝假 H0 的概率)。通常 alpha ↑ ⇒ beta ↓。检验构造原则: 在控制 alpha 的前提下, 最小化 beta 最大化功效)。P 值: 在 H0 为真的假设下, 得到至少与观测值一样极端的检验统计量的概率；

也是能拒绝 H0 的最小显著




性水平。决策规则: $p\text{-value} < \alpha$ 则拒绝 H_0 ; 常见 $\alpha = 0.05$ 但需谨慎使用。P 值越小, 反对 H_0 的证据越强。

Topic 7 Moving beyond Linearity: 多项式回归 (Polynomial)

模型: 多项式逻辑回归假设 logit 概率与预测变量呈多项式关系, 即

$$\text{logit}(\Pr(y_i > 250|x_i)) = \beta_0 + \beta_1 x_i + \cdots + \beta_d x_i^d \quad \varphi$$

Example of Piecewise Cubic




Regression) 模型形式为 $y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \cdots + \beta_d x_i^d + \epsilon_i$ 多项式逻辑回归

(Polynomial Logistic Regression); 阶梯函数 (Step Functions): 阶梯函数用于局部近似非线性结构。它将连续变量转换为有序的二元变量 (哑变量); 在 X 的范围内设定 k 个断点。构建 $k+1$ 个变量利用指示函数

I 来表示 x 落在哪个区间; 所有指示函数之和为 1; X 必须为 $K+1$ 个区间当中一个;

模型: 线性回归函数被替换为 $y_i = \beta_0 + \beta_1 C_1(X_i) + \cdots + \beta_K C_K(X_i) + \epsilon_i \quad \varphi$;



交互项回归模型 (Interaction Regression Model): 有多个预测变量时, 可以

考虑交互作用: 例如 $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_{12} x_{i1} x_{i2} + \epsilon_i$; 分段多项式

For example, a piecewise cubic regression model is

$$y_i = \begin{cases} \beta_{01} + \beta_{11}x_i + \beta_{21}x_i^2 + \beta_{31}x_i^3 + \epsilon_i & \text{if } x_i < c \\ \beta_{02} + \beta_{12}x_i + \beta_{22}x_i^2 + \beta_{32}x_i^3 + \epsilon_i & \text{if } x_i \geq c \end{cases}$$

c is a knot.

(Piecewise Polynomials); 连续分

段多项式 (Continuous Piecewise

条件, 强制拟合曲线必须是连续


Polynomials): 可以添加约束

的, 一阶导二阶导也连续, 保证曲线平滑; 基函数 (Basis Functions):

通用框架: 许多非线性模型可以统一写成 $y_i = \beta_0 + \sum \beta_k b_k(x_i)$ 的形
式, 其中 $b_k(\cdot)$ 是已知且固定的基函数。 φ

例如阶梯函数 bk 是指示函数 I ; 三次样条 (Cubic Spline): 具有连续一阶和二阶导数的连续分段多项式; 截断幂基函数 (truncated power basis function): $h(x, \xi) = (x - \xi)_+^3$

自然
最后
放置




样条 (Natural Cubic Spline): 自然样条要求模型在边界区域 (即第一个节点之前和一个节点之后) 必须是线性的 (红色实线); 确定节点 (Determining Knots): 均匀或者交叉验证之后选择节点数量; 展示了均方误差 (MSE) 随自由度 (Degrees of Freedom, 与节点数量相关) 变化的曲线。呈现 U 型或 L 型, 用于选择最优的模型复杂度; 平滑样条的性质: 最优解 $\hat{g}(x)$ 是一个自然三次样条, 其节点位于每一个唯一的 x_i 上; 调节参数 (Tuning Parameter); 红色线 (16 Degrees of Freedom): 看起来比较“抖动”, 拟合过度; 蓝色线 (6.8 Degrees of Freedom, LOOCV 选定): 通过留一法交叉验证选出的最优平滑度, 曲线更加平滑且合理; 局部线性回归 (Local Linear Regression) 目标: 最小化加权残差平方和; 黄色区域/钟形曲线表示权重函数; 左图: 针对某个数据点 (橙色实心点), 在局部范围内拟合一条直线 (橙色线), 该直线只受附近点的影响; 广义加性模型 (GAMs): 优点: 能自动对每个变量进行非线性建模; 具有可加性, 解释性强 (可以单独考察每个变量的影响); 加性形式排除了变量间的交互作用。如果需要交互, 必须手动将交互项 $f_{ijk}(X_j, X_k)$ 加入模型;

Topic 8 Classification and Regression Trees (CART)


Topic 9 SVM

最大间隔分类器 (Maximal Margin Classifier) —— 理想的线性情况; 基本概念: 当数据是线性可分 (Linearly Separable) 的, 即可以用一条直线 (或超平面) 完美地将两类数据分开时, SVM 试图找到一个“最优”的超平面。什么是“最优”? : 能将两类数据分开的超平面可能有无数个。SVM 选择的是那个拥有最大间隔 (Maximal Margin) 的超平面。间隔 (Margin): 是指数据点到超平面的最小垂直距离。最大化间隔 (Margin): 是指数据点到超平面的最小垂直距离。



- 3. 支持向量机 (SVM) —— 非线性情况
 - 核心思想: 当数据在当前维度 (如 2D) 线性不可分时, SVM 通过将数据映射到更高维的空间 (如 3D 或更高), 使得数据在那个高维空间中变得线性可分。 φ
 - 核技巧 (Kernel Trick): 直接在高维空间计算是非常耗时的。SVM 使用“核函数” $K(x, x')$, 它能够在低维空间中直接计算出高维空间的内积, 从而避免了显式的维度转换, 极大地提高了计算效率。 φ φ
 - 常用核函数:
 - 多项式核 (Polynomial): $K(x, x') = (1 + x^T x')^d$ 。 φ φ
 - 径向基核 (Radial/Gaussian): $K(x, x') = \exp(-\gamma ||x - x'||^2)$, 这是一种局部核, 只有附近的点才会影响预测。 φ φ

超平面两侧留出了最宽的“无人区”(Slab)，这使得模型对新数据的泛化能力更强。支持向量(Support Vectors): 那些恰好落在间隔边缘上的数据点被称为支持向量。它们支撑着这个超平面，如果移动非支持向量的数据点，决策边界不会改变；但如果移动支持向量，决策边界就会改变；图解展示了“最优”的那条分界线(实线)及其间隔(虚线)；支持向量：请注意那些正好落在虚线上的有箭头的点(两个绿色，一个红色)。这些点就是支持向量；展示了支持向量分类器(软间隔)的思想。为了获得更宽、更稳健的间隔(由虚线表示)，



我们允许少量数据点违反规则(即落在间隔内或被错分)。这是一种“退一步海阔天空”的策略；超参数C越大：意味着对错误的容忍度极低(惩罚重)。模型会试图正确分类每一个点，导致间隔变窄；展示了如果我们引入多项式特征；在原始空间看，分界线就变成了非线性的曲线，从而能解决复杂分类问题；左1展示了不同核函数(三阶多项式核/径向基核RBF)的特性。RBF核具有很强的局部性(Local behavior)，非常适合处理这种“中心包围”或局部聚集的复杂分布；

2. 支持向量分类器(Support Vector Classifier)——现实的线性情况
- 问题：现实数据往往不是线性可分的，或者存在离群点。如果强行要求完美分开，间隔会变得极小，模型会对噪声非常敏感(过拟合)。
 - 解决方案(Soft Margin)：我们允许少量数据点“犯错”。即允许它们落在间隔内部，甚至落在错误的一侧。
 - 松弛变量(Slack Variables, ξ_i)：为了实现这一点，引入了松弛变量 ξ_i 。
 - 如果 $\xi_i = 0$ ，点在正确的位置。
 - 如果 $\xi_i > 0$ ，点违反了间隔(在间隔内)。
 - 如果 $\xi_i > 1$ ，点被错误分类。
 - 调节参数C(Tuning Parameter)：C是一个“预算”(Budget)，控制我们能容忍多大的错误总量($\sum \xi_i \leq C$)。
 - 根据课件定义：C越大，容忍度越高，间隔越宽(偏差高，方差低)；C越小，容忍度越低，要求越严格(偏差低，方差高)。(注：不同教材对C的定义可能相反，此处严格遵循课件Slide 24的描述)。

